碳达峰路径论文知识点全景解析

基于北京理工大学统计建模大赛参赛作品的完整学习文档

——从零开始，逐个击破论文中的每一个概念

2026 年

本文档面向零基础大一新生，将论文中涉及的所有概念逐一拆解讲解。
阅读前不需要任何统计学、经济学或计算机基础。

目录

Part I

背景与数据篇

碳达峰与碳中和：最基本的背景

什么是碳排放?

人类在燃烧煤炭、石油、天然气等化石燃料时，会向大气中释放二氧化碳（CO_2）。此外，某些工业生产过程（如水泥制造）也会排放 CO_2。这些排放到大气中的 CO_2 总量，就是**碳排放量**，通常以”百万吨”（Mt，即 Million tonnes）为单位计量。

例子：生活中的类比

想象你家里烧煤取暖。每烧一吨煤，就会向空气中释放一定量的 CO_2。把全中国所有工厂、电厂、汽车、居民……排放的 CO_2 加在一起，就是中国的**碳排放总量**。

什么是”碳达峰”?

概念：碳达峰

碳排放量不再增长，达到最高点后开始下降。这个最高点就叫做”**峰值**”，达到峰值的那一年就是”**达峰年**”。

用一张简单的图来理解：

碳排放量

↗ ↗ → ↘ ↘

峰值 ↑

中国承诺在 **2030 年前**实现碳达峰。

什么是”碳中和”?

概念：碳中和

在一定时期内，排出的 CO_2 与吸收的 CO_2 相互抵消，净排放为零。吸收可以通过植树造林、碳捕集技术等方式实现。

中国承诺在 **2060 年前**实现碳中和。碳达峰是碳中和的前提——你得先让排放不再增长，才谈得上最终降到零。

为什么要研究碳达峰路径?

- **什么时候达峰?** ——太晚达峰意味着留给碳中和的时间不够。
- **峰值有多高?** ——峰值越高，后面下降越困难，成本越大。
- **是什么因素在驱动排放变化?** ——搞清楚”病因”才能”对症下药”。
- **不同政策下未来会怎样?** ——帮政府做决策参考。

这就是这篇论文要回答的核心问题。

数据从哪来? 怎么整理?

CEADs 数据库

概念：CEADs

全称 *Carbon Emission Accounts & Datasets*（碳核算与数据集），是中国学者构建的权威碳排放数据库。它提供中国各省、各年份的碳排放数据，数据来源于化石燃料燃烧和工业过程排放的估算。

提示：论文怎么用 CEADs 的?

CEADs 给出的是**省级**数据（比如北京多少、河北多少……）。论文需要的是**国家级**数据，所以做法很简单——把 31 个省份同年份的排放量**加起来**：

$$C_t = \sum_{i=1}^{N} C_{i,t}$$

其中 $C_{i,t}$ 是第 i 个省第 t 年的碳排放量。这就是论文公式 (1)。

国家统计局数据

除了碳排放量（因变量），论文还需要很多”解释变量”来解释为什么排放会变化。这些数据来自**国家统计局**年度数据库：

- 人口总数
- GDP（国内生产总值）
- 城镇化率
- 第二产业占比

- 能源消费总量
- 煤炭消费占比
- 专利数据（代理技术创新）

什么是”口径统一”？为什么重要？

注意：口径统一——大一新生最容易忽视的问题

假设你想比较 2010 年和 2020 年的 GDP。但 2010 年的 GDP 是用”2000 年不变价” 算的，2020 年用的是”2015 年不变价”，两套标准不一样，直接比较就会出错。**口径统一**就是确保所有年份的数据用同一套标准来度量。

论文提到的三条原则：

1. 同一变量只用一个来源，不混用
2. 优先用连续年份完整的来源
3. 必要时做单位换算，并在分析前做一致性检查

论文中的变量一览

几个变量的计算公式详解

人均 GDP（论文公式 2）

$$A_t = \frac{\mathrm{GDP}_t}{P_t}$$

就是把总 GDP 除以总人口。这衡量的是” 平均每个人创造的经济产出”。

能源强度（论文公式 3）

$$EI_t = \frac{EC_t}{\mathrm{GDP}_t}$$

EC_t 是能源消费总量。能源强度的含义是：**每创造 1 亿元 GDP，需要消耗多少万吨标准煤**。这个值**越小越好**——意味着同样的经济产出只需要更少的能源。

碳强度（论文公式 4）

$$CI_t = \frac{C_t}{\mathrm{GDP}_t}$$

每创造 1 亿元 GDP，排放多少 Mt 碳。也是越小越好。

人均碳排放（论文公式 5）

$$PC_t = \frac{C_t}{P_t}$$

平均每个人排放多少碳。

描述性统计：看数据”长什么样”

概念：描述性统计

用几个简单的数字来概括一批数据的整体特征，最常见的有：

- **均值**：所有值的平均
- **标准差**：数据偏离均值的程度，越大越分散
- **最小值/最大值**：数据的范围

例子：论文中的描述性统计

碳排放总量在 2005–2022 年间：均值约 30566.50 Mt，最小 17516.39 Mt，最大 40358.26 Mt。说明排放总量在这个期间**翻了一倍多**，整体呈显著上升趋势。

相关性矩阵热力图（图 3）

概念：相关系数

衡量两个变量之间线性关系的强弱。取值范围 $[-1, 1]$：

- 接近 $+1$：一个变大，另一个也变大（正相关）
- 接近 -1：一个变大，另一个变小（负相关）
- 接近 0：没有明显的线性关系

提示：论文图 3 告诉我们什么？

热力图中颜色越深（红或蓝），说明相关性越强。论文发现：GDP、能源消费等**规模变量**与碳排放正相关（红色）；煤炭占比下降与减排方向一致（负相关）。这为后面选变量提供了依据。

对数变换：为什么要把数据取对数？

论文中大量使用 ln（自然对数），这是一个非常关键的数据预处理步骤。

概念：对数变换

把原始值 x 变成 $\ln(x)$。比如 $\ln(100) \approx 4.61$，$\ln(10000) \approx 9.21$。

为什么要取对数？三个原因：

1. **把”乘法关系”变成”加法关系”**。比如 $I = P \times A \times T$，取对数后变成 $\ln I = \ln P + \ln A + \ln T$，就可以用线性回归来估计了。
2. **缓解异方差**。经济数据通常”大的值波动更大，小的值波动更小”。取对数后，波动变得更均匀。
3. **系数可以直接解释为弹性**（下文详述）。

注意：什么变量取对数，什么不取？

论文的策略是：

- **规模变量**（人口、GDP、能源强度等）→ 取对数
- **比例变量**（煤炭占比、城镇化率、第二产业占比等）→ **不取**对数，保持原始比例形式

因为比例变量已经在 $[0, 1]$ 范围内，取对数反而会扭曲含义。

标准化

概念：标准化

把变量变成均值为 0、标准差为 1 的形式：

$$x_{\text{new}} = \frac{x - \bar{x}}{s}$$

其中 $\bar{x}$ 是均值，s 是标准差。

提示：论文中标准化用在哪里?

只在**机器学习模型**（XGBoost、随机森林）输入前做标准化。因为不同变量的数量级差异很大（GDP 是几十万亿，城镇化率是小数），标准化可以让模型训练更稳定。OLS 回归没有做标准化，因为对数变换已经缓解了量级问题。

缺失值处理与样本边界

注意：论文的一个关键区分

- **2005–2022 年**：有真实观测数据，用于**机制识别**（回归分析）
- **2023–2024 年**：没有真实碳排放数据（CEADs 还没更新到），仅用于预测的**趋势衔接**，**不参与**回归估计

这个区分非常重要——不能把模型预测出来的值当”真实数据”来用，否则就犯了”用未来解释过去”的错误。

Part II

统计基础篇

OLS 回归：一切的基础

什么是回归?

概念：回归分析

研究一个”结果变量”（因变量 Y）是如何被若干”原因变量”（自变量 $X_1, X_2, \ldots$）影响的。简单说就是：**找关系**。

例子：生活中的回归

假设你想研究”学习时间”对”考试分数”的影响。你收集了 100 个同学的数据，画散点图，发现大致是一条直线关系。这条直线就是”回归线”，它的方程就是”回归方程”。

什么是 OLS?

概念：OLS（普通最小二乘法）

Ordinary Least Squares 的缩写。它是找回归线的一种方法：找到一条线，使得所有数据点到这条线的**垂直距离的平方和**最小。

数学上，对于模型 $Y = \beta_0 + \beta_1 X + \varepsilon$，OLS 的目标是：

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

这里的”二乘”就是”平方”的意思。

多元回归

当有多个自变量时：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

提示：论文中的 STIRPAT 就是多元回归

论文的扩展 STIRPAT 模型（公式 12）有 6 个自变量，就是多元回归。每个 β 代表”在**控制其他变量不变**的情况下，该变量对碳排放的影响”。

弹性

概念：弹性

一个变量变化 1% 时，另一个变量变化百分之几。

例子：弹性的直觉

如果人均 GDP 的弹性是 0.59，意思是：人均 GDP 增加 1%，碳排放增加 0.59%。注意是**百分比变化**，不是绝对量变化。

关键点：对数回归中系数就是弹性。

如果模型是 $\ln Y = \beta \ln X + \cdots$，那么：

$$\beta = \frac{\Delta \ln Y}{\Delta \ln X} \approx \frac{\Delta Y / Y}{\Delta X / X}$$

这就是弹性的定义！所以取对数的一个好处就是**系数直接读作弹性**。

半弹性

概念：半弹性

自变量变化 **1 个单位**（不是 1%）时，因变量变化百分之几。

论文中煤炭占比 CS_t 没有取对数，而 C_t 取了对数，所以 CS_t 的系数是半弹性：煤炭占比每增加 1 个百分点（比如从 60% 到 61%），碳排放变化百分之几。

异方差

概念：异方差

回归模型假设误差项的方差是常数（*同方差*）。如果误差的方差随自变量变化而变化，就叫*异方差*。

例子：异方差的直觉

低收入家庭消费的波动小（吃饭穿衣基本固定），高收入家庭消费的波动大（可以奢侈也可以节俭）。用消费做因变量时，就存在异方差。

提示：对数变换如何缓解异方差？

取对数把数据的”尺度”压缩了。原来从 100 到 10000 差 100 倍，取对数后从 4.6 到 9.2 只差 2 倍，波动变得更均匀。

多重共线性

概念：多重共线性

多个自变量之间高度相关，导致回归系数估计不稳定（标准误变大）。

注意：论文中的巧妙处理

人口 P_t 和人均 GDP $A_t = \text{GDP}/P_t$ 之间天然相关（因为人均 GDP 就是用人口算出来的）。如果同时把人口和人均 GDP 放进回归，会造成严重共线性。论文选择**只用人均 GDP，不放人口**，巧妙避开了这个问题。

统计推断：我们怎么知道结果”靠谱”？

置信区间

概念：95% 置信区间

如果我们重复抽样 100 次，每次都算一个置信区间，大约有 95 个区间会包含真实值。注意：不是说”真实值有 95% 的概率落在这个区间里”（真实值是固定的，不是随机的）。

论文中系数估计的置信区间形式为（公式 13）：

$$\hat{\beta}_j \pm z_{0.975} \cdot \frac{\hat{\sigma}}{\sqrt{[(X^\top X)^{-1}]_{jj}}}$$

- $\hat{\beta}_j$：系数的点估计值
- $z_{0.975} \approx 1.96$：标准正态分布的 97.5% 分位数
- 后面的部分：标准误（衡量估计的不确定性）

例子：论文中的实例

煤炭占比的弹性估计值是 3.3791，95% 置信区间是 $[0.0469, 6.7112]$。这个区间**不包含 0**，说明煤炭占比对碳排放的影响在统计上是显著的。
而人均 GDP 的弹性是 0.5882，置信区间是 $[-0.9264, 2.1027]$。这个区间**包含 0**，说明在当前样本下，我们不能确定人均 GDP 对碳排放到底是正影响还是负影响。

显著性检验与 p 值

概念：p 值

在”该变量对因变量没有影响”（原假设）的前提下，观察到当前数据或更极端数据的概率。p 值越小，越有理由拒绝原假设，即认为该变量”确实有影响”。

- $p < 0.05$：在 95% 置信水平下显著（论文用的标准）
- $p < 0.01$：在 99% 置信水平下显著
- $p \geq 0.05$：不显著

提示：置信区间与显著性检验的关系

等价判断：95% 置信区间不包含 0 $\iff$ $p < 0.05$。论文用置信区间来判断显著性，和用 p 值是一回事。

自由度

概念：自由度

可以”自由变化”的数据个数。在回归中：

$$\text{自由度} = n - k$$

其中 n 是样本量，k 是要估计的参数个数（包括截距项）。

注意：论文的核心痛点：自由度严重不足！

论文有 18 年数据（2005–2022），要估计 7 个参数（6 个自变量 + 1 个截距），所以自由度只有 $18 - 7 = 11$。
这**非常少**。自由度越小，置信区间越宽，越难得到”显著”的结果。论文中很多变量不显著，**不是**因为它们真的没影响，而是因为数据太少，统计检验”功力不够”。

例子：类比

想象你要判断一枚硬币是否均匀。抛 10 次，可能还看不出规律。抛 10000 次，就很有把握了。自由度就像”抛硬币的次数”——次数越多，判断越准确。论文只有 11 个自由度，相当于只抛了 11 次。

Part III

机制识别模型篇

IPAT 恒等式：一切的起点

IPAT 是什么?

概念：IPAT 恒等式

环境影响（I）= 人口（P）× 富裕度（A）× 技术（T）：

$$I = P \times A \times T$$

这是一个**恒等式**（等号一定成立），不是回归模型。它只是把环境影响分解成三个因素的乘积。

- I（Impact）：环境影响，这里指碳排放

- P（Population）：人口
- A（Affluence）：富裕度，通常用人均 GDP
- T（Technology）：技术水平，通常定义为 $I/(P \times A)$，即单位人口单位 GDP 的排放

注意：IPAT 的局限

IPAT 假设三个因素的**弹性都是 1**（即人口增加 1%，排放一定增加 1%）。这太死板了。现实中弹性可能大于 1 也可能小于 1。IPAT 不能做统计检验，只是一个会计分解。

STIRPAT 模型：论文的核心解释模型

从 IPAT 到 STIRPAT

概念：STIRPAT

Stochastic Impacts by Regression on Population, Affluence, and Technology。它把 IPAT 的固定关系变成**随机**的、可估计的**回归**模型。

具体做法：给每个因素加上指数参数，再加一个随机误差：

$$I = a \cdot P^b \cdot A^c \cdot T^d \cdot e \quad \text{（论文公式 10）}$$

- a 是常数系数
- b, c, d 是**弹性参数**——不再固定为 1，而是由数据估计出来
- e 是随机误差

两边取对数得到（论文公式 11）：

$$\ln I_t = \ln a + b \ln P_t + c \ln A_t + d \ln T_t + \ln e_t$$

这就可以用 OLS 来估计了！$\hat{b}, \hat{c}, \hat{d}$ 就是各个因素的弹性。

论文的” 扩展”STIRPAT

概念：扩展 STIRPAT

在标准三因素（人口、富裕度、技术）基础上，加入更多与现实相关的变量，使模型更贴合中国实际。

论文的扩展形式（公式 12）：

$$\ln C_t = \beta_0 + \beta_1 \ln A_t + \beta_2 \ln EI_t + \beta_3 CS_t + \beta_4 UR_t + \beta_5 TP_t + \beta_6 IS_t + \varepsilon_t$$

论文 STIRPAT 的核心结果解读

论文原话解读：论文发现：只有煤炭占比显著！

在 95% 置信水平下，**只有煤炭占比**的弹性显著不为零（弹性约 3.3791）。其他变量虽然点估计方向与直觉一致，但置信区间太宽、包含了零，不够显著。

怎么理解弹性 3.3791？ 煤炭占比每增加 1 个百分点，碳排放增加约 3.38%。这个影响非常大！

为什么其他变量不显著？ 核心原因是**自由度太少**（只有 11），不是它们没影响。论文明确说了：”并不否定其经济机制上的现实作用”。

EKC 环境库兹涅茨曲线

什么是库兹涅茨曲线？

概念：库兹涅茨曲线（原始版）

经济学家 Kuznets 发现：随着经济发展，收入不平等先变大后变小，呈倒 U 型。

什么是环境库兹涅茨曲线（EKC）？

概念：EKC 假说

把这个逻辑搬到环境领域：随着人均收入增长，环境污染先恶化后改善，呈**倒 U 型**。

直觉理解：

1. **穷的时候**：首要目标是发展经济，不太管环境 → 排放增加
2. **中等收入时**：工业高速发展 → 排放达到最高
3. **富裕之后**：有财力和技术来治理环境 → 排放下降

符号	名称	单位	直觉含义
C_t	碳排放总量	Mt	我们要解释和预测的对象
P_t	总人口	万人	人越多，排放越多?
A_t	人均 GDP	万元/人	越富裕，排放越多?
EI_t	能源强度	万吨标煤/亿元	每单位 GDP 消耗多少能源
CS_t	煤炭占比	比例	能源中煤炭占多少
UR_t	城镇化率	比例	城镇人口占总人口比
IS_t	第二产业占比	比例	工业占 GDP 的比重
TP_t	技术进步代理	—	用专利数等代表技术水平

表 1: 论文核心变量一览

变量	含义	预期方向	为什么?
$\ln A_t$	人均 GDP	+	越富裕，消耗越多能源
$\ln EI_t$	能源强度	+	单位 GDP 能耗越高，排放越多
CS_t	煤炭占比	+	煤是最”脏”的化石能源
UR_t	城镇化率	±	可能增加（基建），也可能减少（集约化）
TP_t	技术进步	−	技术进步提高效率，减少排放
IS_t	第二产业占比	+	工业是高排放行业

表 2: 各变量的预期影响方向

EKC 的数学形式（论文公式 6）

$$\ln C_t = \alpha_0 + \alpha_1 \ln A_t + \alpha_2 (\ln A_t)^2 + \varepsilon_t$$

这是一个关于 $\ln A_t$ 的**二次函数**。当 $\alpha_1 > 0$ 且 $\alpha_2 < 0$ 时，曲线呈倒 U 型。

如何找”拐点”?（论文公式 7、8）

对 $\ln A_t$ 求导，令导数为零：

$$\frac{\partial \ln C_t}{\partial \ln A_t} = \alpha_1 + 2\alpha_2 \ln A_t = 0$$

解出拐点处的人均 GDP：

$$A^* = \exp\left(-\frac{\alpha_1}{2\alpha_2}\right)$$

例子：拐点的含义

如果拐点对应人均 GDP 为 5 万元，意思是：当人均 GDP 超过 5 万元时，经济增长不再带来排放增加，反而排放开始下降。中国是否已经过了这个拐点？论文通过数据来检验。

提示：论文的定位

论文明确说 EKC 检验的作用不是”证明因果关系”，而是判断”经济规模扩张是否已出现边际减排拐点**迹象**”。这是一个非常谨慎的学术表述。

中介效应分析

什么是中介效应?

概念：中介效应

自变量 X 影响因变量 Y，但这个影响可能是**通过**中间变量 M 间接实现的。M 就是”中介变量”。

例子：生活例子

锻炼（X）→ **减轻体重**（Y）。但锻炼不是直接让你变瘦的，而是通过 → **消耗卡路里**（M）→ 减轻体重。这里”消耗卡路里”就是中介变量。

中介效应的三步法（论文公式 14–16）

1. **a 路径**：X 是否影响 M？

$$M_t = \gamma_0 + \gamma_1 X_t + u_t$$

如果 γ_1 显著，说明 X 确实影响 M。

2. **c 路径（总效应）**：X 是否影响 Y？（不考虑 M）

$$Y_t = \delta_0 + \delta_1 X_t + v_t$$

δ_1 是总效应。

3. **c' 路径 + b 路径**：控制 M 后，X 对 Y 的直接效应，以及 M 对 Y 的效应：

$$Y_t = \theta_0 + \theta_1 X_t + \theta_2 M_t + w_t$$

效应分解（论文公式 17）

$$\underbrace{\delta_1}_{\text{总效应}} = \underbrace{\theta_1}_{\text{直接效应}} + \underbrace{\gamma_1 \cdot \theta_2}_{\text{间接效应（中介效应）}}$$

- **直接效应** θ_1：不通过 M 的那部分影响
- **间接效应** $\gamma_1 \cdot \theta_2$：通过 M 传导的那部分
- 如果 $|\theta_1| < |\delta_1|$ 且间接效应显著 $\rightarrow$ **部分中介**
- 如果 θ_1 不显著且间接效应显著 $\rightarrow$ **完全中介**

论文中的中介分析结果

论文原话解读：一个非常精彩的发现：”符号反转”

论文设 X = 煤炭占比，M = 技术进步，Y = 碳排放。
奇怪的现象：在不控制 GDP 时，煤炭占比对碳排放的系数是**负的**（$c = -3.31$）！这违反直觉——煤炭占比越高，排放应该越多才对。
原因：2005–2022 年间，中国 GDP 和碳排放在涨，但煤炭占比在降。简单回归把这种”时间上的反向趋势”误读成了因果关系。
控制 GDP 后：煤炭占比的直接效应变成**正的**（$c' = 2.22$），符合物理直觉！这就是**伪相关**的经典案例，也说明了多变量控制的重要性。

提示：中介分析的核心结论

能源替代（降煤炭占比）的减排逻辑**主要靠直接效应**（直接压降高碳底座），**不是**靠间接的技术创新传导。间接效应虽然有，但太小了。所以政策应该直接盯着”降煤”这个目标。

Kaya 恒等式与 LMDI 分解（文献综述中提到）

概念：Kaya 恒等式

把碳排放分解为四个因素的乘积：

$$C = \text{人口} \times \frac{\text{GDP}}{\text{人口}} \times \frac{\text{能源}}{\text{GDP}} \times \frac{\text{碳排放}}{\text{能源}}$$

即：$C = P \times$ 人均 GDP $\times$ 能源强度 $\times$ 碳排放系数

概念：LMDI 分解

Logarithmic Mean Divisia Index。一种把碳排放的**变化量**分解为各因素**贡献量**的方法。比如今年排放比去年多了 100Mt，LMDI 可以告诉你：其中 50Mt 是因为 GDP 增长，$-30Mt$ 是因为能源强度下降，等等。

提示：LMDI vs STIRPAT

- LMDI：做**事后归因**——”过去的变化是怎么来的”
- STIRPAT：做**边际效应估计**——”各因素的弹性有多大”

论文选择了 STIRPAT 路线，因为更适合与预测和情景模拟衔接。

Part IV

时间序列基础篇

时间序列的基本概念

什么是时间序列数据?

概念：时间序列

按时间顺序排列的数据。比如中国 2005 年的碳排放、2006 年的碳排放……直到 2022 年。每一年只有一个数据点，这就是**时间序列**（区别于**截面数据**——同一时间多个个体的数据，和**面板数据**——多个个体多年的数据）。

平稳性

概念：平稳时间序列

均值、方差、自相关结构**不随时间变化**的序列。直观地说，就是” 没有趋势、没有周期性波动变化，始终在一个固定水平附近波动”。

例子：平稳 vs 不平稳

- **平稳**：每天抛硬币的结果序列。均值始终是 0.5，方差始终不变。
- **不平稳**：中国 GDP 序列。每年都在涨，均值每年都在变。

单位根与 I(1) 过程

概念：单位根

一种导致不平稳的” 根源”。如果一个序列有单位根，对它做任何冲击，影响都会**永久持续**，不会消失。

概念：I(1) 过程——” 一阶单整”

原始序列不平稳（有单位根），但做**一阶差分**后变平稳。一阶差分就是用今年的值减去去年的值：$\Delta C_t = C_t - C_{t-1}$。

例子：I(1) 的直觉

中国的碳排放每年都在涨，不平稳。但” 每年比上一年多排了多少”，这个变化量大致在一个范围内波动，可能是平稳的。这就叫 I(1)。

单位根检验

概念：单位根检验

用统计方法检验一个序列是否有单位根（即是否不平稳）。常见的方法有 ADF 检验、PP 检验等。

- 原假设 H_0：有序列单位根（不平稳）
- 备择假设 H_1：无单位根（平稳）
- 如果 $p < 0.05$，拒绝原假设，认为序列平稳

论文原话解读：论文的发现

论文提到”单位根检验表明序列为 I(1) 过程”，即碳排放序列不平稳、有一阶单位根。这解释了为什么 AR 模型（利用差分/滞后信息）比水平拟合的复杂模型更稳健。

伪回归

注意：伪回归——时间序列分析中的头号陷阱

当两个**都不平稳**的序列做回归时，即使它们之间**完全没有关系**，回归结果也可能表现出很高的 R^2 和”显著”的系数。这就是伪回归。

例子：经典例子

有人拿”中国的碳排放”和”美国某条河的水位”做回归，可能发现”显著正相关”。但这纯粹是因为两个序列都在涨（都有趋势），不是真有关系。

协整

概念：协整

两个不平稳的 I(1) 序列，如果存在某个**线性组合**是平稳的，就说它们有协整关系。协整意味着两个序列之间存在**真实的长期均衡关系**，不是伪回归。

注意：论文为什么没做协整检验?

论文明确说明：样本量只有 18，传统 Johansen 协整检验在这种极小样本下”统计功效不足”（即检验能力太弱，分不出真假）。所以论文把 STIRPAT 的结果定位为”弹性方向参考”而非”严谨因果推断”，把最终结论放在不需要平稳性假设的滚动预测和情景模拟上。这是一个**非常诚实的学术处理**。

Part V

预测模型篇

滚动一步预测：论文的评估方法

什么是”滚动一步预测”?

概念：滚动一步向前预测

预测第 t 期时，**只用**第 1 到第 $t-1$ 期的数据来训练模型，然后预测第 t 期。接着窗口向前滚动一期，用 1 到第 t 期的数据预测第 $t+1$ 期。如此反复。

例子：与”全样本拟合”的区别

全样本拟合：用 2005–2022 年全部数据训练，然后”预测”这些年本身。这相当于考试时提前看了答案，当然分数很高。

滚动预测：用 2005–2010 年数据预测 2011 年，再用 2005–2011 年预测 2012 年……每次预测都是”真刀真枪”的，不能偷看答案。

提示：为什么论文选择滚动预测?

因为论文关心的是**模型对未来新数据的预测能力**（外推能力），而不是对历史数据的拟合能力。滚动预测严格避免了”未来信息泄露”，是最诚实的评估方式。

七种预测模型逐一讲解

模型 1：朴素模型（Naive）（论文公式 18）

$$\hat{C}_t = C_{t-1}$$

概念：朴素模型

最简单的预测方法：明天的排放量 = 今天的排放量。假设排放遵循”随机游走”——没有趋势，没有规律，纯随机波动。

提示：朴素模型的作用

它是一个**基准**。如果你的复杂模型连朴素模型都打不过，那这个复杂模型就是废的。就像你训练了一个 AI 模型来做预测，结果还不如”直接猜昨天的值”，那这个 AI 就没意义了。

模型 2：二阶自回归模型 AR2（论文公式 19）

$$\hat{C}_t = \phi_0 + \phi_1 C_{t-1} + \phi_2 C_{t-2}$$

概念：自回归模型（AR 模型）

用变量**过去的值**来预测**未来的值**。AR2 就是用前两期的值来预测下一期。

例子：AR2 的直觉

”过去两年排放分别是 38000 和 39000，按照这个惯性，今年大概是……”AR2 就是把这个”惯性”用数学公式表达出来。ϕ_1 和 ϕ_2 由 OLS 在训练窗口内估计。

论文原话解读：论文的冠军模型

AR2 在滚动预测中表现**最好**：RMSE=1323.36，MAPE=3.32%。一个简单的线性模型打败了所有复杂的机器学习模型！这说明了什么？**在数据极少的情况下，简单模型往往更可靠。**

模型 3：二次趋势模型（论文公式 20）

$$\hat{C}_t = \eta_0 + \eta_1 t + \eta_2 t^2$$

概念：二次趋势模型

假设碳排放随时间呈**抛物线**趋势。$\eta_2 > 0$ 表示加速上升，$\eta_2 < 0$ 表示增速放缓或出现拐点。

注意：趋势外推的危险

这个模型假设未来会延续历史的趋势形状。但如果趋势发生”结构性变化”（比如突然强力减排政策），趋势外推就会严重失准。

模型 4：多变量回归模型（论文公式 21–22）

$$\hat{C}_t = \lambda_0 + \sum_{k=1}^{K} \lambda_k X_{k,t}$$

把 GDP、能源消费、煤炭占比等 6 个变量同时放进回归来预测碳排放。参数通过 OLS 估计：

$$\hat{\lambda} = (X^\top X)^{-1} X^\top C$$

注意：为什么表现不好?

18 个数据点要估计 7 个参数（6 个变量 + 截距），自由度只有 11。变量之间还有相关性（共线性）。结果就是估计出来的系数不稳定，预测误差很大。

模型 5：随机森林（论文公式 23）

概念：随机森林

一种**集成学习**方法。核心思想：建很多棵”决策树”，每棵树用不同的数据子集和特征子集来训练，最后把所有树的预测结果**取平均**。

什么是决策树?

概念：决策树

像一个”20 个问题” 游戏。每次选一个特征做判断（比如” 人均 GDP 是否超过 5 万？ ”），把数据分成两半，然后在每一半继续判断，直到分出最终结果。

随机森林为什么叫” 随机”?

两个” 随机”：

1. **数据随机**：每棵树用随机抽取的子集训练（有放回抽样，叫 *Bagging*）
2. **特征随机**：每次分裂只考虑随机选出的部分特征

注意：论文中随机森林为什么崩了?

随机森林通常需要成千上万个数据点才能发挥优势。论文只有 18 个数据点，每棵树能分的数据太少，容易”记住”训练数据的噪声而不是学到真实规律。这就是**过拟合**（下文详述）。RMSE 高达 5054.08，比朴素模型差 3 倍。

模型 6：XGBoost（论文公式 24–25）

概念：XGBoost

eXtreme Gradient Boosting。一种**梯度提升树**方法。与随机森林不同，XGBoost 的树是**一棵一棵按顺序建**的：第一棵树拟合原始数据，第二棵树拟合第一棵树的**残差**（预测值与真实值的差），第三棵树拟合第二棵树的残差……最终预测是所有树的加和。

XGBoost 的正则化

论文公式 25 中有一个正则项：

$$\Omega(f_m) = \gamma J + \frac{1}{2}\lambda \|w\|^2$$

- J：叶节点数量——节点越多，树越复杂
- w：叶节点的权重值
- γ 和 λ：正则化系数，控制对复杂度的惩罚力度

提示：正则化的直觉

就像考试时老师限制你”最多只能用 3 个公式来解题”。限制越多，你越不容易”死记硬背”特定题目（过拟合），而是被迫学到通用方法。

注意：XGBoost 在论文中的表现

RMSE=5214.83，MAPE=15.47%，**所有模型中最差**（和多变量回归一起垫底）。原因同样是数据太少导致严重过拟合。

模型 7：集成模型（论文公式 26–27）

$$\hat{C}_t^{(\text{ens})} = \omega_1 \hat{C}_t^{(\text{AR2})} + \omega_2 \hat{C}_t^{(\text{Trend})} + \omega_3 \hat{C}_t^{(\text{Multi})}$$

概念：集成模型

把多个模型的预测结果**加权平均**。权重按照各模型在验证集上的 RMSE 倒数来确定：

$$\omega_j = \frac{1/\text{RMSE}_j}{\sum_{j=1}^{3} 1/\text{RMSE}_j}$$

误差越小的模型权重越大。

提示：集成的逻辑

”三个臭皮匠顶个诸葛亮”。如果不同模型犯了不同的错误，取平均后错误会相互抵消。但如果所有模型犯同样的错误（比如都低估了），集成也没用。

七种模型的误差比较总结

评估指标详解

RMSE：均方根误差（论文公式 28）

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(C_t - \hat{C}_t)^2}$$

概念：RMSE

先算每个预测值与真实值的差，**平方**后求平均，再开根号。单位与原始数据相同。

提示：RMSE 的特点

对**大误差**惩罚更重（因为先平方了）。如果有个别年份预测偏差特别大，RMSE 会明显变大。适合”不能容忍极端错误”的场景。

MAE：平均绝对误差（论文公式 29）

$$\text{MAE} = \frac{1}{n}\sum_{t=1}^{n}|C_t - \hat{C}_t|$$

概念：MAE

预测误差绝对值的平均。单位与原始数据相同。

提示：MAE vs RMSE

MAE 对大误差不那么敏感，更”宽容”。如果有一个年份偏差特别大，RMSE 会飙升，但 MAE 只会温和上升。MAE 更**鲁棒**（robust）。

MAPE：平均绝对百分比误差（论文公式 30）

$$\text{MAPE} = \frac{1}{n}\sum_{t=1}^{n}\left|\frac{C_t - \hat{C}_t}{C_t}\right| \times 100\%$$

概念：MAPE

用误差占真实值的**百分比**来衡量，**无量纲**。3.32% 的 MAPE 意味着平均预测偏差约为真实值的 3.32%。

提示：MAPE 的优势

可以跨不同量纲的数据比较。比如你预测碳排放的 MAPE 是 3%，预测温度的 MAPE 是 5%，可以说”碳排放预测得更好”，尽管它们单位不同。

MAPE 的解读标准

例子：论文中 MAPE=3.32% 意味着什么？

AR2 模型的 MAPE=3.32%，属于”高精度预测”。而 XGBoost 的 MAPE=15.47%，虽然按标准还算”良好”，但和 AR2 比差了将近 5 倍，在同样数据下这个差距是不可接受的。

过拟合：论文最核心的方法论教训

什么是过拟合？

概念：过拟合

模型在**训练数据**上表现很好，但在**新数据**上表现很差。本质是模型”死记硬背”了训练数据的噪声和特殊特征，而不是学到了通用规律。

例子：一个通俗的类比

欠拟合：学生太懒，连课本上的例题都不会做。
良好拟合：学生理解了方法，能做课本上的题，也能做考试中的新题。
过拟合：学生把课本上每道题的**答案**都背下来了，课本上的题全对。但考试时题目稍微一变，就完全不会了。
XGBoost 和随机森林在论文中就是第三种情况——在训练数据上可能拟合得很好，但遇到新数据（滚动预测时）就崩了。

为什么会过拟合?

1. **模型太复杂**：参数太多、树太深、特征太多
2. **数据太少**：模型有足够的能力”记住”每一个数据点
3. **噪声太多**：数据中的随机波动被模型当成了规律

注意：论文的极端案例

18 个数据点 + XGBoost（可以建很深的树）= **教科书级的过拟合**。XGBoost 有足够的灵活性把 18 个点几乎完美地”连”起来，但这些连接方式完全是针对这 18 个点的，没有任何泛化能力。

如何避免过拟合?

1. **选简单的模型**：像论文中的 AR2
2. **增加数据量**：论文做不到（数据就这么多）
3. **正则化**：如 XGBoost 中的 γ 和 λ，但小样本下可能不够
4. **交叉验证**：但时间序列不太适合标准交叉验证
5. **用滚动预测评估**：论文的做法，最能反映真实外推能力

论文原话解读：论文的核心方法论启示

”**模型适配性优先于模型复杂度**”。不是越复杂的模型越好，而是**与数据规模匹配**的模型最好。在小样本场景下，简单的线性模型往往完胜复杂机器学习模型。这个结论虽然反直觉，但在学术界已经被反复验证。

Part VI

可解释性与情景模拟篇

SHAP 值：让” 黑箱” 变透明

为什么需要 SHAP?

XGBoost、随机森林等模型被称为” 黑箱”——你只知道输入和输出，不知道内部是怎么做决策的。SHAP 就是为了解决” 黑箱可解释性” 问题。

什么是 SHAP 值?

概念：SHAP

SHapley Additive exPlanations。源于博弈论中的 Shapley 值思想：在一个” 合作博弈” 中，每个参与者对总收益的贡献是多少?

例子：Shapley 值的原始场景

三个人合作做生意赚了 100 万。A 出了资金，B 出了技术，C 出了人脉。怎么分这 100 万才公平? Shapley 值给出了一种数学上公允的分法：考虑每个人在所有可能的” 组合” 中的边际贡献。

SHAP 在机器学习中的应用

把上面的场景搬到机器学习：

- ” 合作博弈” → ” 模型预测”
- ” 参与者” → ” 特征变量”
- ” 总收益” → ” 预测值”

SHAP 值回答的问题是：**对于某一个预测结果，每个特征贡献了多少?**
论文公式 (35) 给出了 SHAP 值的精确定义：

$$\phi_j(t) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \left[\hat{f}_{S \cup \{j\}}(x^t_{S \cup \{j\}}) - \hat{f}_S(x^t_S) \right]$$

提示：不用被这个公式吓到

直觉就是：对于特征 j，考虑所有**不包含** j 的特征子集 S，计算” 加入 j 后预测值的变化”，然后对所有可能的子集取**加权平均**。这个加权平均就是特征 j 的 SHAP 值。

SHAP 值的三个公理性质

1. **效率性**：所有特征的 SHAP 值之和 = 预测值 − 基线值（即” 贡献加起来等于总变化”）
2. **对称性**：如果两个特征对模型的贡献相同，它们的 SHAP 值也相同
3. **虚拟性**：如果某个特征对预测没有影响，它的 SHAP 值为 0

全局重要性与局部解释

- **全局重要性**：论文用 $|\phi_j|$ 的均值来衡量。即在所有样本点上，特征 j 的 SHAP 值绝对值的平均。值越大说明这个特征整体上越重要。
- **局部解释**：对于某一次具体预测，看每个特征的 SHAP 值，知道” 这次预测主要被哪些特征驱动”。

论文中 SHAP 分析的深刻发现

论文原话解读：SHAP 揭示了 XGBoost 的” 懒惰”

SHAP 显示：人均 GDP 的重要性**远超**其他所有变量，城镇化率和技术进步的重要性为 **0**。

为什么？ 因为在 18 期数据中，人均 GDP 和碳排放几乎完美同步增长。XGBoost 只需要一个分裂节点（” 人均 GDP 是否超过某阈值？ ”）就能把低排放年份和高排放年份完美分开。它” 懒得” 再去挖掘其他变量的作用了。

对比 STIRPAT：STIRPAT 是多元线性回归，**强制**所有变量同时入模、同时竞争解释力。正是这种” 强制”，让它识别出了煤炭占比的独立弹性。

结论：SHAP 分析没有推翻 STIRPAT，反而从算法行为的角度证明了——小样本下复杂模型不仅预测差，连机制识别都会” 偏废”。

情景模拟：如果政策不同，未来会怎样？

什么是情景模拟?

概念：情景模拟

设定不同的**假设条件**（如不同的减排力度），分别推算未来的可能路径。不是预测”一定会怎样”，而是回答” 如果怎样，就会怎样”。

例子：类比

天气预报说” 如果明天是晴天，最高温 35°C；如果是阴天，最高温 28°C”。这不是在预测到底是晴天还是阴天，而是在告诉你不同条件下分别会怎样。情景模拟的逻辑一样。

论文的三种情景（论文公式 31–34）

以 2022 年排放量为起点，设定三种不同的” 衰减路径函数” $g^{(s)}(k)$：

基准情景

$$g^{(\text{base})}(k) = 1 - 0.0035k + 0.00015 \cdot \max(k-3, 0)^2$$

含义：维持现有政策，排放缓慢下降，后期因技术积累降速略快。

低碳情景

$$g^{(\text{low})}(k) = 1 - 0.014k$$

含义：加速能源结构优化和产业升级，排放以较快**线性**速率下降。

深度脱碳情景

$$g^{(\text{deep})}(k) = 1 - 0.024k$$

含义：能源替代与效率提升**协同强化**，以最快速率压减排放。

其中 $k = t - 2022$ 是距 2022 年的年数。

例子：算一算

到 2035 年（$k = 13$）：

- 基准：$g = 1 - 0.0035 \times 13 + 0.00015 \times 100 = 1 - 0.0455 + 0.015 = 0.9695$，排放约为 2022 年的 96.95%
- 低碳：$g = 1 - 0.014 \times 13 = 0.818$，排放约为 2022 年的 81.8%
- 深度脱碳：$g = 1 - 0.024 \times 13 = 0.688$，排放约为 2022 年的 68.8%

情景参数的来源

论文表 4 列出了各情景下关键参数的设定：

- GDP 年均增速：基准约 5%，低碳 4.6%，深度脱碳 4.4%
- 煤炭占比年均变动：低碳每年降 1.1 个百分点，深度脱碳降 1.6 个百分点
- 能源强度年均下降：低碳 2.8%，深度脱碳 3.6%

提示：参数不是拍脑袋定的

这些参数参考了《”十四五”现代能源体系规划》和国家统计局近年宏观数据，是有依据的”合理假设”。

2035 年预测结果

提示：怎么读这个结果？

从基准到深度脱碳，2035 年排放差距超过 1.1 亿吨。这意味着如果政策力度足够大，可以在 2035 年前多减排约 1.1 亿吨——这为政策制定提供了明确的**量化激励**。

Part VII

论文写作与方法论篇

论文的总体框架设计

五步逻辑链

论文的结构可以概括为一条清晰的逻辑链：

模型	RMSE	MAE	MAPE(%)	一句话点评
AR2	1323.36	1054.50	3.32	**最佳**，简单但稳健
Naive	1732.09	1440.44	4.79	最简单的基准，居然排第二
Quadratic Trend	2081.10	1805.35	5.50	趋势外推，尚可接受
Ensemble	2612.10	1772.16	5.70	集成没带来额外优势
Random Forest	5054.08	4540.33	14.27	**严重过拟合**
XGBoost	5214.83	5056.28	15.47	**最差**，复杂度惩罚
Multivariate OLS	5959.72	2909.50	10.13	变量太多，自由度不足

表 3: 七种预测模型误差比较

MAPE 范围	预测质量评价
$< 10\%$	高精度预测
$10\% - 20\%$	良好预测
$20\% - 50\%$	合理预测
$> 50\%$	不可接受

表 4: MAPE 的一般评价标准

情景	2035 年碳排放
基准	39127.33
低碳	33013.06
深度脱碳	27766.48

1. **数据整合**：CEADs + 国家统计局 → 统一口径的国家级时序数据
2. **机制识别**：EKC + STIRPAT + 中介分析 → ”为什么排放会变？”
3. **预测比较**：七种模型滚动预测 → ”哪种模型预测最准？”
4. **情景模拟**：三种政策情景 → ”不同政策下未来怎样？”
5. **政策解释**：把统计结果翻译成政策语言

提示：这个框架好在哪？

很多论文只做”机制解释”或只做”预测”，这篇把两者**打通**了——用机制分析的结果来支撑情景设定，用预测比较的结果来选择模拟工具。各章节之间不是孤立的，而是一个整体。

文献综述的写法

论文的文献综述按”三条研究路线”组织：

1. 碳排放驱动因素研究：恒等式分解 → 计量回归 → 系统协同
2. 碳排放预测方法研究：传统统计 → 机器学习 → 多模型比较
3. 情景模拟与政策评估研究

最后总结”三点不足”：

1. 机制解释与预测精度分离
2. 用样本内拟合评价预测能力（不真实）
3. 情景分析与机制识别脱节

提示：文献综述的标准写法

不是简单罗列”张三说了什么、李四说了什么”，而是**按主题线索**组织，最后指出**已有研究的不足**，从而自然引出”本文要做什么、为什么有价值”。论文做到了这一点。

稳健性分析：怎么证明结论”站得住脚”?

概念：稳健性分析

用不同的方法、不同的假设、不同的数据子集来检验同一个结论。如果结论在各种变化下都成立，就说结论是”稳健的”。

论文中的稳健性策略包括：

- 多模型比较：不只依赖一个模型
- 滚动预测 vs 样本内拟合：用更严格的评估标准
- 跨方法互证：STIRPAT 和 SHAP 从不同角度得出一致结论
- 附录补充：残差诊断、增速对比、滚动相关热力图等
- 明确区分观测值、预测值、情景值

局限性讨论：诚实的学术态度

论文明确承认了以下局限：

1. 国家级时序样本长度有限（只有 18 期）
2. 技术进步和治理变量用代理指标，不够精确
3. 聚焦国家总量，未做区域和行业分解
4. 未做严格协整检验（因为样本太小）
5. 情景参数设定仍有一定主观性

提示：为什么要写局限性?

在学术论文中，**主动承认局限**不是减分项，反而是加分项。它说明作者清楚自己研究的边界，没有过度解读结果。审稿人/评委最反感的是”把相关性说成因果”、”把小样本结论当普适真理”。

Part VIII

附录：关键公式速查表

公式速查表

名称	公式	一句话解释
碳排放汇总	$C_t = \sum_{i=1}^{N} C_{i,t}$	各省排放加总
人均 GDP	$A_t = \mathrm{GDP}_t / P_t$	总 GDP 除以总人口
能源强度	$EI_t = EC_t / \mathrm{GDP}_t$	单位 GDP 能耗
碳强度	$CI_t = C_t / \mathrm{GDP}_t$	单位 GDP 碳排放
EKC 检验	$\ln C_t = \alpha_0 + \alpha_1 \ln A_t + \alpha_2 (\ln A_t)^2 + \varepsilon_t$	倒 U 型检验
EKC 拐点	$A^* = \exp(-\alpha_1 / 2\alpha_2)$	拐点处人均 GDP
STIRPAT 原版	$\ln I = \ln a + b \ln P + c \ln A + d \ln T + \ln e$	IPAT 的随机化扩展
扩展 STIRPAT	$\ln C_t = \beta_0 + \beta_1 \ln A_t + \beta_2 \ln EI_t + \beta_3 CS_t + \beta_4 UR_t + \beta_5 TP_t + \beta_6 IS_t + \varepsilon_t$	六因素模型
置信区间	$\hat{\beta}_j \pm 1.96 \cdot \mathrm{SE}(\hat{\beta}_j)$	95% 置信区间
中介 a 路径	$M_t = \gamma_0 + \gamma_1 X_t + u_t$	X 对 M 的影响
中介 c 路径	$Y_t = \delta_0 + \delta_1 X_t + v_t$	X 对 Y 的总效应
中介 c'+b 路径	$Y_t = \theta_0 + \theta_1 X_t + \theta_2 M_t + w_t$	直接效应 + 中介效应
效应分解	$\delta_1 = \theta_1 + \gamma_1 \cdot \theta_2$	总 = 直接 + 间接
朴素预测	$\hat{C}_t = C_{t-1}$	随机游走基准
AR2	$\hat{C}_t = \phi_0 + \phi_1 C_{t-1} + \phi_2 C_{t-2}$	二阶自回归
二次趋势	$\hat{C}_t = \eta_0 + \eta_1 t + \eta_2 t^2$	抛物线趋势
多变量 OLS	$\hat{C}_t = \lambda_0 + \sum \lambda_k X_{k,t}$	多元回归预测
随机森林	$\hat{C}_t^{(\mathrm{RF})} = \frac{1}{B} \sum_{b=1}^{B} T_b(X_t)$	多树取平均
XGBoost	$\hat{C}_t^{(\mathrm{XGB})} = \sum_{m=1}^{M} f_m(X_t)$	逐步拟合残差
集成模型	$\hat{C}_t^{(\mathrm{ens})} = \sum \omega_j \hat{C}_t^{(j)}$	加权平均
RMSE	$\sqrt{\frac{1}{n} \sum (C_t - \hat{C}_t)^2}$	均方根误差
MAE	$\frac{1}{n} \sum \lvert C_t - \hat{C}_t \rvert$	平均绝对误差
MAPE	$\frac{1}{n} \sum \left\lvert \frac{C_t - \hat{C}_t}{C_t} \right\rvert \times 100\%$	平均百分比误差
情景路径	$C_t^{(s)} = C_{T_0} \cdot g^{(s)} (t - T_0)$	不同政策下的路径

核心术语中英对照表

中文	英文	缩写
碳达峰	Carbon Peak	–
碳中和	Carbon Neutrality	–
碳排放	Carbon Emissions	–
环境库兹涅茨曲线	Environmental Kuznets Curve	EKC
普通最小二乘法	Ordinary Least Squares	OLS
弹性	Elasticity	–
半弹性	Semi-elasticity	–
置信区间	Confidence Interval	CI
显著性水平	Significance Level	–
自由度	Degrees of Freedom	df
异方差	Heteroscedasticity	–
多重共线性	Multicollinearity	–
平稳性	Stationarity	–
单位根	Unit Root	–
一阶单整	Integrated of Order 1	I(1)
伪回归	Spurious Regression	–
协整	Cointegration	–
自回归模型	Autoregressive Model	AR
随机森林	Random Forest	RF
梯度提升树	Gradient Boosting	–
极端梯度提升	eXtreme Gradient Boosting	XGBoost
集成学习	Ensemble Learning	–
过拟合	Overfitting	–
正则化	Regularization	–
滚动预测	Rolling Forecast	–
情景模拟	Scenario Simulation	–
SHAP 值	SHapley Additive exPlanations	SHAP
对数变换	Log Transformation	–
标准化	Standardization	–
中介效应	Mediation Effect	–
描述性统计	Descriptive Statistics	–
相关系数	Correlation Coefficient	–

中文	英文	缩写
能源强度	Energy Intensity	EI
煤炭消费占比	Coal Share	CS
城镇化率	Urbanization Rate	UR
第二产业占比	Secondary Industry Share	IS

——全文完——

本文档覆盖了原论文中出现的所有核心概念、公式与方法。
建议按目录顺序阅读，每学完一个概念后回到论文对应位置对照理解。
遇到不理解的地方，多看”例子”和”论文原话解读”两个框。